증권·자산운용 부문

한국 시장에서의 딥러닝 기반 Enhanced Index Tracking 재현

퀀티파이일팀

초록

본 연구는 Dai & Li (2024)의 딥러닝 기반 Index Tracking 프레임워크를 기반으로, 국내 KOSPI200 데이터를 활용하여 Index Tracking(IT)과 Enhanced Index Tracking(EIT) 전략의 성과를 비교·분석한다. 2-상태 가우시안 HMM을 통해 시장 및 개별 종목의 bull/bear 레짐 확률을 추정하고, 이를 정책 신경망의 입력으로 활용하여 동적 포트폴리오 비중을 학습하였다. 학습은 블록 부트스트랩 기반 경로 시뮬레이션과 거래비용을 고려한 논문 일관적 트레이딩 메커니즘 하에서 수행되었다.

연도별 롤링 백테스트(2017-2022)를 통해 IT는 Tracking Error 최소화 측면에서 안정적 성과를 보였으며, EIT는 초과수익을 유의하게 개선하면서도 추적오차를 일정 수준 유지하는 결과를 보였다. 이는 단순 추적 전략을 넘어, 레짐 인식 기반 딥러닝 구조가 위험 대비 성과 개선에 기여할 수 있음을 시사한다.

Keywords: Deep Learning, Enhanced Index Tracking, Excess Return, Hidden Markov Model, Index Tracking, Portfolio Optimization, Regime Switching, Tracking Error

1. 서론

최근 패시브 투자 시장의 급격한 성장과 함께 지수 추종(Index Tracking) 전략의 중요성이 크게 확대되고 있다. 특히 ETF(Exchange Traded Fund) 시장의 확대는 저비용·투명성·분산투자 효과를 제공하는 지수 기반 투자전략의 수요를 지속적으로 증가시키고 있다. 전통적인 Index Tracking 문제는 주어진 벤치마크 지수와의 Tracking Error(추적오차)를 최소화하는 포트폴리오를 구성하는 것으로 정의되며, 이는 일반적으로 이차계획법(quadratic programming) 기반의 최적화 문제로 접근되어 왔다.

그러나 단순 추적 전략은 지수를 모방하는 데 초점을 두기 때문에 초과수익을 창출하기 어렵다는 구조적 한계를 가진다. 이에 따라 최근 연구에서는 Tracking Error를 일정 수준 유지하면서도 벤치마크 대비 초과성과를 추구하는 Enhanced Index Tracking(EIT) 접근이 제안되고 있다. EIT는 추적오차 최소화와 초과수익 극대화를 동시에 고려하는 목적함수를 통해 전통적인 추적 전략을 확장한 형태이다.

한편, 금융시장은 경기 국면에 따라 수익률의 평균과 분산이 달라지는 레짐(regime) 특성을 보이는 것으로 알려져 있다. 이러한 레짐 전환 특성을 반영하기 위해 Hidden Markov Model(HMM) 기반의 상태 추정 기법이 널리 활용되어 왔다. 최근에는 딥러닝 기반 정책 신경망(policy network)을 활용하여 레짐 확률과 단기 통계량을 입력으로 동적 자산배분 전략을 학습하는 연구도 등장하였다. 특히 Dai & Li (2024)는 4-블록 구조의 정책 신경망을 제안하여 Index Tracking 문제를 경로 기반(path-wise) 손실 최소화 문제로 재정의하였다.

본 연구는 Dai & Li (2024)의 프레임워크를 국내 KOSPI200 시장에 적용하여 실증적으로 검증하는 것을 목적으로 한다. 구체적으로 2-상태 가우시안 HMM을 통해 시장 및 개별 종목의 bull/bear 레짐 확률을 추정하고, 이를 정책 신경망의 입력으로 활용하여 동적 포트폴리오 비중을 학습한다. 또한 연도별 롤링 재학습 구조와 거래비용을 반영한 일관적 트레이딩 메커니즘 하에서 IT와 EIT 전략의 성과를 비교 분석한다.

본 연구의 기여는 다음과 같다. 첫째, 해외 시장을 대상으로 제안된 딥러닝 기반 Index Tracking 구조를 한국 주식시장에 적용하여 외부 타당성을 검증한다. 둘째, 연도별 롤링 재학습 방식을 통해 실전 운용 환경과 유사한 설정에서 전략의 안정성을 평가한다. 셋째, Tracking Error 중심의 IT 전략과 초과성과를 고려한 EIT 전략을 동일한 학습 프레임워크 하에서 직접 비교함으로써 목적함수 설계의 경제적 효과를 분석한다.

이하에서는 관련 선행연구를 검토한 후, 연구설계 및 방법론을 설명하고, 실증 결과를 통해 두 전략의 성과를 비교·해석한다.

2. 선행연구

지수추종(Index Tracking, IT)은 벤치마크 지수와의 괴리를 최소화하는 포트폴리오를 구성하는 문제로, 전통적으로 추적오차(tracking error)를 최소화하는 최적화 문제로 정식화되어 왔다. 추적오차 제약 하의 포트폴리오 최적화 문제를 체계적으로 분석한 대표적 연구로는 Jorion (2003)이 있다. 그는 추적오차 제약이 추가될 경우 전통적 평균-분산 최적화 구조가 어떻게 변형되는지를 분석하며, 단순 TE 최소화가 항상 효율적인 자산배분으로 이어지지는 않음을 보였다. 이러한 연구는 IT 문제를 단순 모방이 아닌 "제약 하의 능동적 운용" 관점에서 이해하는 이론적 기반을 제공한다.

이후 IT 연구는 부분복제(partial replication) 및 제약 조건을 포함한 실무형 최적화 문제로 확장되었다. Oh, Kim, and Min (2005)은 유전자 알고리즘을 활용하여 KOSPI200 추종 포트폴리오 구성을 시도하며, 종목 수 제한(cardinality constraint)이 존재하는 상황에서 휴리스틱 기반 접근이 효과적일 수 있음을 보였다. 이는 전통적 이차계획법 기반 접근을 넘어, 계산 복잡성과 실무 제약을 동시에 고려한 확장 연구로 평가된다.

한편 단순 추적 전략의 구조적 한계를 보완하기 위해, 추적오차를 관리하면서도 초과수익을 동시에 추구하는 Enhanced Index Tracking(EIT) 접근이 제안되었다. EIT는 TE 최소화와 초과수익 극대화를 결합한 목적함수를 통해 IT를 확장한 형태로 이해된다. 이러한 흐름은 최근 들어 머신러닝 및 딥러닝 기반 접근과 결합되면서 새로운 전환점을 맞이하였다.

특히 Dai and Li (2024)는 IT 및 EIT 문제를 경로 기반(path-wise) 손실 최소화 문제로 재정의하고, 정책 신경망(policy network)이 직접 포트폴리오 비중을 산출하는 end-to-end 학습 구조를 제안하였다. 이 연구는 (i) 인덱스 및 개별 종목의 레짐 확률을 Hidden Markov Model(HMM)로 추정하고, (ii) 단기 통계량과 결합한 입력 특징을 구성하며, (iii) 거래비용을 포함한 트레이딩 메커니즘 하에서, (iv) 블록 부트스트랩 기반 시뮬레이션 경로로 정책을 학습한다는 점에서 기존 정적 최적화 연구와 구별된다. 이는 레짐 정보, 거래 마찰, 목적함수 설계를 하나의 통합 프레임워크로 묶은 점에서 의미가 크다.

딥러닝과 자산배분을 결합한 연구는 Jiang, Xu, and Liang (2017)의 강화학습 기반 포트폴리오 관리 연구에서도 확인된다. 해당 연구는 심층 강화학습을 이용해 포트폴리오 비중을 동적으로 조정하는 구조를 제안하며, 금융시장에서 end-to-end 학습의 가능성을 보여주었다. 또한 Moody and Saffell (2001)은 순환신경망을 이용한 강화학습 기반 트레이딩 시스템을 제안하여, 금융 시계열과 학습 기반 의사결정의 결합 가능성을 조기에 제시하였다. 이러한 연구들은 본 연구의 딥러닝 기반 정책망 접근과 이론적 맥락을 공유한다.

한국시장과 관련해서는 ETF 추적오차 및 인덱스 추종 전략에 관한 실증 연구가 축적되어 왔다. 정재만 (2012)은 KOSPI200 추적 ETF의 추적오차를 분석하여, 시장 상황 및 운용 특성에 따라 추적오차가 달라질 수 있음을 보고하였다. 윤주영 (2013)은 KOSPI200 ETF 간 추적오차 차이를 분석하고, 보수율·펀드 규모·보유 종목 수 등의 요인이 추적오차에 영향을 미친다는 실증 결과를 제시하였다. 또한 윤주영·반주일 (2014)은 ETF의 액티브 리스크와 추적오차의 결정요인을 분석하며 규모의 경제 효과를 제시하였다.

종합하면, 선행연구는 (i) 추적오차 제약 기반의 정적 최적화(IT)에서 출발하여, (ii) 부분복제 및 실무 제약을 고려한 확장, (iii) 초과수익을 결합한 EIT 접근, (iv) 최근에는 레짐 정보와 딥러닝 기반 정책망을 활용한 동적 학습 구조로 발전해 왔다. 그러나 한국 KOSPI200 시장을 대상으로 Dai and Li (2024) 유형의 딥러닝 기반 IT/EIT 프레임워크를 롤링 재학습 및 거래비용 환경 하에서 비교·검증한 연구는 아직 제한적이다. 따라서 본 연구는 딥러닝 기반 EIT 구조의 국내시장 적용 가능성과 목적함수 설계의 경제적 효과를 실증적으로 점검한다는 점에서 기존 연구를 확장한다.

3. 문제 구성

3.1. 포트폴리오 수익률과 동적 비중

본 연구는 주어진 벤치마크 지수에 대한 인덱스 트래킹(Index Tracking, IT) 및 향상된 인덱스 트래킹(Enhanced Index Tracking, EIT) 문제를 이산시간 확률적 제어 문제로 정식화한다. 사전에 선정된 n개 종목만을 거래하며, 이들 종목과 현금으로 구성된 포트폴리오에서 각 시점의 구성 비중을 어떻게 설정하고 갱신할지를 핵심 문제로 둔다. 시점 t에서 종목 i의 비중을 $w_{i,t}(i=1,\dots,n)$, 현금 비중을 $w_{0,t}$로 두며, 모든 시점에 대해 $\sum_{i=0}^{n} w_{i,t}=1$이 성립한다. 주식 비중 벡터는 $\mathbf{w}_{S,t}=(w_{1,t},\dots,w_{n,t})\in\mathbb{R}^n$로 정의한다.

포트폴리오 운용에는 거래비용을 반영한다. 본 연구에서는 주식 매매에 대해서만 비례 거래비용률 ρ가 발생하며, 현금의 입출금에는 비용이 없다고 가정한다. 시점 t에서 리밸런싱이 수행되면, 리밸런싱 직전의 포트폴리오 가치 $v_{P,t}$를 기준으로 각 자산의 목표 비중 $\widetilde{w}_{i,t}$ 를 결정한다. 거래비용은 주식 비중 변화의 절대값 합(회전율)에 비례하여 차감되므로, 리밸런싱 후 현금 비중은

$$\widetilde{w}_{0,t}=1-\sum_{i=1}^{n}\widetilde{w}_{i,t}-\rho\sum_{i=1}^{n}|\,\widetilde{w}_{i,t}-w_{i,t}\,|$$

로 주어진다. 따라서 거래비용이 존재하는 경우 $\sum_{i=0}^{n}\widetilde{w}_{i,t}\le 1$ 이며, 비용 차감으로 인해 총 비중이 1 보다 작아질 수 있다. 또한 공매도와 레버리지를 허용하지 않으므로 리밸런싱 후 주식 비중(제어 변수)은 $\widetilde{w}_{i,t}\ge 0(i=1,\dots,n)$ 을 만족하고, 현금 비중이 음수가 되지 않도록 $1-\sum_{i=1}^{n}\widetilde{w}_{i,t}\ge 0$을 만족해야 한다. 즉 제어의 허용 영역은

$$\left\{\widetilde{\mathbf{w}}_{S,t}\in\mathbb{R}^n \mid 1-\sum_{i=1}^{n}\widetilde{w}_{i,t}\ge 0,\ \widetilde{w}_{i,t}\ge 0,\ i=1,\dots,n\right\}$$

으로 주어지며, 현금 비중 $\widetilde{w}_{0,t}$은 위 거래비용 반영 식에 의해 결정되므로 별도의 제어 변수가 아니다.

이제 포트폴리오 수익률과 비중 전이식을 정의한다. 종목 i 의 $t \to t+1$ 단순수익률을 $r_{i,t+1}$, 현금 수익률을 0 으로 두면, 한 기간 포트폴리오 단순수익률은 리밸런싱 목표 비중과 거래비용을 반영하여

$$r_{P,t+1} = \sum_{i=0}^{n} \widetilde{w}_{i,t}\, r_{i,t+1} - \rho \sum_{i=1}^{n} |\, \widetilde{w}_{i,t} - w_{i,t} \,|$$

로 정의된다. 즉 비용 차감 후의 수익률이 포트폴리오 성과 측정 및 학습에 사용된다. 수익이 실현된 이후 다음 시점의 비중은 자산별 수익률에 따라 자연스럽게 드리프트(drift)하며, 그 결과는

$$w_{i,t+1} = \frac{\widetilde{w}_{i,t}(1 + r_{i,t+1})}{\sum_{j=0}^{n} \widetilde{w}_{j,t}\,(1 + r_{j,t+1})}, \qquad i = 0, \dots, n$$

으로 갱신된다. 본 연구의 운용은 매일 리밸런싱하지 않고 T_{rb} 거래일마다 수행하며, 실험에서는 $T_{rb} = 5$를 사용한다.

3.2. 목적함수

다음으로 목적함수를 정의한다. 지수 수익률을 $r_{I,t}$로 두고, 포트폴리오 및 지수 수익률 과정이 약한 정상성(weak stationarity)을 가진다고 가정한다. 기대 트래킹 에러는

$$L_{TE} = \sqrt{\mathbb{E}\big[(r_{P,t} - r_{I,t})^2\big]}$$

로 정의하며, 구현에서는 표본 평균 $\hat{L}_{TE} = \mathrm{mean}((r_P - r_I)^2)$을 사용한다. 기대 초과수익은

$$L_{ER} = \mathbb{E}\big[r_{P,t} - r_{I,t}\big]$$

로 정의하고, 표본으로는 $\hat{L}_{ER} = \mathrm{mean}(r_P - r_I)$을 사용한다. Index Tracking(IT)은 트래킹 성능만을 고려하는 설정으로, 목적은 $L_{IT} = L_{TE}$를 최소화하는 것이다. 반면 Enhanced Index Tracking(EIT)은 트래킹 에러를 줄이면서 동시에 초과수익을 늘리는 것을 목표로 하며, $\lambda \geq 0$를 도입하여

$$L_{EIT} = L_{TE} - \lambda L_{ER}$$
$$= \sqrt{\mathbb{E}\left[(r_{P,t} - r_{I,t})^2\right]} - \lambda \mathbb{E}\left[r_{P,t} - r_{I,t}\right]$$

를 최소화한다. $\lambda = 0$이면 EIT 는 IT 와 동일해진다.

---

4. 딥러닝

우리는 확률적 제어 문제를 시점 t 에서의 특징 벡터 $\boldsymbol{F}_t$ 를 입력으로 받아 제어(리밸런싱 목표 비중) $\tilde{\mathbf{w}}_{S,t} \in \mathbb{R}^n$를 출력하는 단일 신경망 정책으로 푼다. 정책은 시점에 관계없이 동일한 네트워크를 사용한다

3.1. 피처 (Features)

인덱스와 개별 종목의 레짐(regime)은 관측되지 않으므로, 수익률로부터 HMM 으로 추정한다. 인덱스와 각 종목의 일별 수익률에 대해 2-상태(=bull/bear) 가우시안 HMM 을 두고, EM 으로 모수를 추정한 뒤 forward 알고리즘으로 필터링 확률을 계산한다

(구현에서는 bull 상태 확률을 사용하고, 확률을 이동평균으로 스무딩한다)

특징 벡터 $\boldsymbol{F}_t$는 다음 네 가지로 구성한다.

(1) 인덱스 레짐 확률(스무딩) $\bar{p}_{I,t} \in [0,1]$

인덱스가 bull 상태(상태 1)에 있을 확률 $p_{I,t} = P(q_{I,t} = 1 \mid \boldsymbol{r}_{I,1:t})$ 를 사용하며, 노이즈를 줄이기 위해 이동평균 스무딩을 적용한 $\bar{p}_{I,t}$를 사용한다

(2) 종목별 레짐 확률(스무딩) $\bar{\mathbf{p}}_{S,t} \in [0,1]^n$

각 종목 i에 대해 $p_{i,t} = P(q_{i,t} = 1 \mid r_{i,1:t})$를 계산하고, 인덱스와 동일한 방식으로 스무딩해 $\bar{\mathbf{p}}_{S,t}$를 만든다

(3) 단기 피처 $\boldsymbol{F}_{st,t} \in \mathbb{R}^{3n+2}$

최근 k일(구현: 63 거래일)의 단기 통계를 사용한다: 종목별 $\hat{\mu}_i^{(k)}, \hat{\sigma}_i^{(k)}, \hat{\beta}_i^{(k)}$와 인덱스 $\hat{\mu}_I^{(k)}, \hat{\sigma}_I^{(k)}$를 쌓아 입력으로 쓴다.

(Score block 에는 종목별 5 차원 $[\mu_i, \sigma_i, \beta_i, \mu_I, \sigma_I]$형태로 들어간다)

(4) 현재 주식 비중 $\mathbf{w}_{S,t} \in \mathbb{R}^n$

리밸런싱 직전의 주식 비중으로, 거래비용(턴오버)에 직접 영향을 주기 때문에 정책 입력에 포함한다.

3.2 신경망 구조 (Neural Network Architecture)

정책은 블록 단위 설계이며, 각 블록이 서로 다른 피처를 반영한다. 전체 출력은 주식 비중만 내고, 현금은 softmax 출력에서 첫 성분(현금)을 버리거나(혹은 잔여 비중) 시뮬레이터에서 암묵적으로 처리한다 .

(1) Main block

목표는 인덱스 레짐(장기 시장 상황)에 따라 bull/bear 에서 서로 다른 주식 비중을 학습하는 것이다. 스무딩된 인덱스 레짐 확률 $\bar{p}_{I,t}$만을 입력으로 받아 스칼라 $\omega_{bull} \in (0,1)$을 만든 뒤 bull/bear 비중을 선형 결합한다.

$$\tilde{\mathbf{w}}_{1,t} = \omega_{bull}\tilde{\mathbf{w}}_{bull} + (1 - \omega_{bull})\tilde{\mathbf{w}}_{bear}$$

$\tilde{\mathbf{w}}_{bull}, \tilde{\mathbf{w}}_{bear}$는 제약을 만족시키기 위해 $\theta_{bull}, \theta_{bear} \in \mathbb{R}^{n+1}$에 softmax 를 적용한 뒤 현금 성분을 제외해 정의한다.

(2) Score block

단기 피처로 각 자산(현금+종목)을 점수화해 비중을 만든다. 모든 종목이 하나의 공유 FNN 을 사용한다(종목 수가 커져도 구조 유지). 각 자산의 5 차원 입력(종목은 $[\mu_i, \sigma_i, \beta_i, \mu_I, \sigma_I]$, 현금은 $\mu, \sigma, \beta = 0$)을 점수로 변환하고, 점수 벡터에 softmax 를 적용한 뒤 주식 성분만 취해 $\tilde{\mathbf{w}}_{sc,t}$를 얻는다 .

이후 Main block 결과와 가중 결합한다.

$$\tilde{\mathbf{w}}_{2,t} = (1 - \omega_1)\tilde{\mathbf{w}}_{sc,t} + \omega_1\tilde{\mathbf{w}}_{1,t}$$

여기서 $\omega_1 \in (0,1)$은 학습되는 스칼라(Sigmoid 파라미터)다.

(3) Gate block

종목별 레짐 확률(스무딩) $\bar{p}_{i,t}$를 입력으로 각 종목 게이트 $\tilde{g}_{i,t} \in (0,1)$를 출력하고, 종목별로 비중을 축소/확대한다. 이 블록도 종목 간 공유 FNN 을 사용한다.

$$\widetilde{\mathbf{w}}_{3,t} = \tilde{\mathbf{g}}_t \odot \widetilde{\mathbf{w}}_{2,t}.$$

(4) Memory block

제안 비중 $\widetilde{\mathbf{w}}_{3,t}$가 현재 비중 $\mathbf{w}_{S,t}$와 크게 다르면 거래비용이 커지므로, 회전율

$$\Delta w = \| \widetilde{\mathbf{w}}_{3,t} - \mathbf{w}_{S,t} \|_1$$

을 입력으로 스칼라 $\omega_p \in (0,1)$를 출력하고, 최종 비중을 선형 결합으로 만든다 :

$$\widetilde{\mathbf{w}}_{S,t} = (1-\omega_p)\widetilde{\mathbf{w}}_{3,t} + \omega_p \mathbf{w}_{S,t}.$$

거래비용이 없는 경우($\rho = 0$)에는 Memory block 이 불필요하므로, 2 단계 학습(1 단계: 상위 3 블록 학습, 2 단계: 상위 3 블록 고정 후 Memory 만 학습)을 사용한다는 설정을 둔다.

또한 피처의 상대적 중요도를 보기 위해, 블록 사용 여부를 달리한 4 가지 변형을 사용한다. 4 가지 변형의 블록 구조는 table 1 에 정리되어있다.

마지막으로 벤치마크로는 재최적화(RO)를 사용한다. 즉, 각 시점에서 데이터를 갱신해 목적함수를 직접 최소화하는 $\theta \in \mathbb{R}^{n+1}$를 찾고

$$\widetilde{\mathbf{w}}_{S,t} = \mathrm{Softmax}(\theta)_{2:n+1}$$

로 비중을 구성하는 방식이다.

Table 1. 신경망 네트워크 정책

Policy	Features	Main block	Score block	Gate block	Memory block
NN-ST	$\boldsymbol{F}_{st,t}, \widetilde{\mathbf{w}}_{S,t}$		✓		✓
NN-IR	$p_{I,t}, \widetilde{\mathbf{w}}_{S,t}$	✓			✓
NN-ISR	$p_{I,t}, \bar{\mathbf{p}}_{S,t}, \widetilde{\mathbf{w}}_{S,t}$	✓		✓	✓
NN-All	all	✓	✓	✓	✓

4. 실증 연구 (Empirical Study)

본 절에서는 KOSPI200 을 대상으로 IT, EIT 를 실증 분석한다.

4.1 데이터, 연구 설계, 성과 지표

Dataguide 에서 2000 년 1 월 3 일부터 2022 년 12 월 30 일까지 KOSPI200 에 상장된 기업들의 일별 수정 종가와 2016 년 12 월 30 일 기준 자유유통 시가총액 데이터를 수집하였다. 그 중 2000 년 1 월 3 일 이후 상장 종목은 제외한 후, 시가총액 상위 다섯 종목을 선정하였다. 선정된 다섯 가지 종목은 삼성전자, SK 하이닉스, 현대차, 한국전력, 현대모비스이다. 현금 계정에 대해서는 수익률을 0 으로 가정하였다.

롤링 학습·테스트를 통해 데이터 활용을 극대화한다. 매 테스트 연도 초에 인덱스·종목 HMM 을 재추정하고, 2000 년 1 월 3 일부터 누적된 전 학습 데이터로 신경망 정책을 다시 학습한다. 학습 경로는 겹치는 블록 부트스트랩으로 생성하며, 총 길이 T_{total} 인 $(n+1)$ 차원 수익률에서 길이 $T_{\text{train}} = 200$ 인 모든 구간을 모아 $(T_{\text{total}} - T_{\text{train}} + 1)$개 경로를 만들고, 500 개를 검증용으로 무작위 추출한 뒤 나머지를 학습에 사용한다.

성과 평가는 2017 년 초~2022 년 말(6 년) 테스트 구간의 일별 포트폴리오·인덱스 수익률로 수행하며, 2020 년 급락과 2022 년 bear 구간 등을 포함한다. 성과 평가를 위한 지표들은 아래와 같다.

- 트래킹 에러 (TE): $\sqrt{\frac{1}{T_{\text{test}}} \sum_{t=1}^{T_{\text{test}}} (r_{P,t} - r_{I,t})^2}$.
- 평균 초과수익 (MER): $\frac{1}{T_{\text{test}}} \sum_{t=1}^{T_{\text{test}}} (r_{P,t} - r_{I,t})$.
- 손실 (Loss): IT·EIT 는 $\text{TE} - \lambda \times \text{MER}$.
- 정보비율 (IR): 일별 초과수익의 표본평균을 표준편차로 나눈 값,

$$\text{IR} := \frac{\text{MER}}{\text{std}(r_P - r_I)}.$$

- 누적수익률 (CR): $\prod_{t=1}^{T_{\text{test}}} (1 + r_t) - 1$. ($r_t$는 해당 일별 수익률 경로.)
- 샤프 비율: $\text{Sharpe} := \frac{\text{mean}(r_P)}{\text{std}(r_P)}$. 테스트 기간 대부분 무위험 이자율이 0 에 가깝기 때문에 무시.
- 최대 낙폭 (MDD): 시점별 자산가치 v_t와 그 시점까지의 최고점 M_t에 대해

$$\mathrm{MDD} := \max_{1 \le t \le T} \frac{M_t - v_t}{M_t}.$$

- CVaR: 테스트 기간 일별 수익률로 추정한 95% CVaR.
- 거래당 평균 거래비용 (ATC): 리밸런싱 시점 t에서 $\rho \sum_{i=1}^{n} |\tilde{w}_{i,t} - w_{i,t}|$를 리밸런싱 전 포트폴리오 가치 $v_{P,t}$에 대한 비율로 계산하고, 6년 테스트 기간 동안 발생한 모든 거래에 대해 표본평균을 낸 값.

MER, IR, CR, 샤프 비율은 수익 지표이고, MDD와 CVaR은 위험 지표이다. 모든 수익 지표는 거래비용을 차감한 후 계산한다.

4.2 실험 설정

손실 함수의 표본 근사 m개의 일별 데이터 경로가 있고 각 경로 길이가 T_{train}일 때, 아래 표본 기반 손실을 최소화한다. 수렴을 위해 100배 스케일을 적용한다.

- IT:

$$\hat{L}_{IT} = 100 \times \sqrt{\frac{1}{mT_{\text{train}}} \sum_{t=1}^{T_{\text{train}}} \sum_{j=1}^{m} (r_{P,t}^{(j)} - r_{I,t}^{(j)})^2}.$$

- EIT:

$$\hat{L}_{EIT} = \hat{L}_{IT} - 100 \times \frac{\lambda}{mT_{\text{train}}} \sum_{t=1}^{T_{\text{train}}} \sum_{j=1}^{m} (r_{P,t}^{(j)} - r_{I,t}^{(j)}).$$

하이퍼파라미터 설정은 $c = 3\%$, $\alpha = 5\%$로 했는데, 2000-2016년 KOSPI200 일별 수익률의 95% CVaR이 약 3% 수준이라 $c = 3\%$로 두었다.

아래는 설정한 하이퍼파라미터에 대해 선택한 값이다.

- 네트워크:
- Main, Gate, Memory 블록: 입력이 1차원이므로 은닉 1층, 5노드.
- Score 블록: 입력 차원 5이므로 은닉 2층, 각 5노드.
- 은닉층 활성화: GELU.
- 출력층: Main · Gate · Memory는 Sigmoid, Score는 항등(identity).
- 리밸런싱: 리밸런싱 간격 $T_{rb} = 5$
- 시간 윈도우: 레짐 확률은 노이즈가 많아 덱스·종목 모두 최근 2거래일 평균으로 스무딩. 단기 피처는 최근 63거래일(약 3개월) 데이터로 계산.

- 거래비용: $\rho = 0$과 $\rho = 0.005$ (5%). 한국 주식의 평균 거래비용이 25bp 이하라는 문헌과 맞춰, 실무보다 보수적으로 잡은 수준이다.
- 초기 비중: 첫 테스트일(2017년 1월 3일) 전 $w_{i,0} = 0$ ($i = 1, \ldots, n$), $w_{0,0} = 1$(전부 현금). 롤링할 때 다음 테스트 연도의 초기 비중은 직전 연도 말 비중으로 이어받는다.
- SGD: 미니배치 128경로(경로당 200일), 학습률 10^{-2}의 Adam optimizer. 모든 신경망 정책은 50 에포크 학습. 매 에포크마다 검증 집합으로 정책을 평가하고, 50번 중 검증 손실이 가장 좋았던 파라미터를 샘플 외 테스트에 사용한다.
- 단기 피처(종목별 롤링 평균·변동성·베타, 인덱스 평균·변동성) 5차원 벡터에 대해, 훈련 구간에서 추정한 표본평균과 표준편차를 이용한 z-score 정규화를 선택적으로 적용하여, Score block 입력의 스케일을 맞추었다.

RO 정책표준 재최적화(RO)를 구현해 RO 정책으로 부른다. 우리 프레임워크에서 RO는 리밸런싱 후 비중 $\tilde{\mathbf{w}}_{S,t}$를 직접 최적화하고 어떤 피처에도 의존하지 않는 특수한 경우로 볼 수 있다. 신경망 정책과 동일하게 5 거래일마다 리밸런싱한다. 각 리밸런싱 시점에서는 최근 2년 일별 수익률만 사용하고, 블록 크기 10일로 부트스트랩한다. 미니배치 크기는 동일하게 두고 에포크는 200으로 두었다.

4.3 결과 해석

4.3.1 누적 수익률 및 성과 지표 분석

Figure 1-4는 테스트 구간(2017-2022)의 누적수익률 경로를 보여준다. 연두색 음영은 bull regime, 연노란색 음영은 bear regime를 의미하며, 이는 HMM 기반 시장 국면 분류에 따라 구분된 것이다. Table 2는 IT 목적함수 하의 성과 지표를, Table 3은 EIT 목적함수 하의 성과 지표를 요약한다.

먼저 IT 목적함수 하에서(Table 2), 모든 전략은 전반적으로 지수를 밀접하게 추종하는 모습을 보인다. 이는 TE 최소화를 직접적으로 목표로 하기 때문이다. Table 2에서 가장 두드러진 결과는 RO가 모든 설정에서 가장 낮은 TE를 기록한다는 점이다. 이는 단기 평균-분산 기반 재최적화가 순수 추적 문제에서는 여전히 가장 효율적인 접근임을 의미한다. IR과 Sharpe ratio 역시 RO가 상대적으로 안정적인 값을 보이며,

변동성 대비 일관된 추종 성과를 나타낸다. 반면 신경망 기반 전략들은 TE 측면에서 RO 보다 약간 높은 값을 보이지만, 일부 설정에서는 MER 이나 누적수익률(CR)에서 근소한 개선이 관찰된다. 이는 신경망이 단순 추종을 넘어 약한 초과수익 신호를 반영하고 있음을 시사한다. 그러나 IT 환경에서는 CR 격차가 크지 않으며, Table 2 의 전반적 수치는 추적 정확성이 성과의 핵심임을 보여준다.

Figure 상에서도 bull 구간(연두색)에서는 전략 간 경로 차이가 크지 않으며, bear 구간(연노란색)에서도 대부분 지수와 유사한 낙폭을 보인다. 다만 정규화(normON)를 적용한 NN-All 과 NN-ST 는 일부 하락 구간에서 낙폭이 상대적으로 완만하거나 회복 속도가 빠르게 나타난다. 이는 정규화가 입력 특성의 스케일 왜곡을 제거함으로써 하락 국면에서 보다 빠른 재조정을 가능하게 했음을 시사한다.

EIT 목적함수(Table 3)로 전환하면 상황은 현저히 달라진다. Table 3 에서 가장 뚜렷한 특징은 NN-ST 와 NN-All 이 MER 및 CR 측면에서 RO 를 유의하게 상회한다는 점이다. 이는 λ=20 설정 하에서 MER 항이 손실 함수에 강하게 반영되면서 초과수익 추구 전략이 구조적으로 유리해졌기 때문이다. 특히 NN-ST 는 bull 구간에서 가장 높은 CR 을 기록하며, Figure 에서도 2021 년 강한 상승장에서 가장 가파른 상승 경로를 보인다. Table 3 의 Sharpe ratio 역시 NN-ST 가 상위권을 차지하며, 위험 대비 수익 측면에서도 경쟁력을 나타낸다.

Table 2. Policy performances (IT, KOSPI200)

	TE	MER	IR	CVaR	CR	Sharpe	MDD	ATC
(a) 5 Stocks ($\rho = 0$), no normalization								
NN-ST	6.34×10^{-3}	-5.76×10^{-5}	-0.009	0.021	0.063	0.009	0.322	n.a
NN-IR	5.60×10^{-3}	-2.38×10^{-5}	-0.004	0.022	0.112	0.012	0.316	n.a
NN-ISR	5.50×10^{-3}	-4.30×10^{-6}	-0.001	0.022	0.144	0.014	0.315	n.a
NN-All	6.01×10^{-3}	9.10×10^{-6}	0.002	0.018	0.189	0.018	0.257	n.a
RO	5.02×10^{-3}	7.29×10^{-5}	0.015	0.021	0.28	0.022	0.321	n.a
KOSPI200				0.027	0.120	0.012	0.412	
(b) 5 Stocks ($\rho = 0$), normalization								
NN-ST	5.50×10^{-3}	6.88×10^{-5}	0.013	0.025	0.232	0.018	0.343	n.a
NN-IR	5.61×10^{-3}	-2.38×10^{-5}	-0.004	0.022	0.112	0.012	0.316	n.a
NN-ISR	5.50×10^{-3}	-4.30×10^{-6}	-0.001	0.022	0.144	0.014	0.315	n.a
NN-All	5.20×10^{-3}	8.02×10^{-5}	0.015	0.019	0.304	0.024	0.291	n.a
RO	4.92×10^{-3}	7.29×10^{-5}	0.015	0.021	0.28	0.022	0.321	n.a
KOSPI200				0.027	0.120	0.012	0.412	
(c) 5 Stocks ($\rho = 0.005$), no normalization								
NN-ST	6.30×10^{-3}	-8.00×10^{-5}	-0.013	0.021	0.028	0.007	0.336	0.012
NN-IR	5.58×10^{-3}	-3.71×10^{-5}	-0.007	0.022	0.09	0.011	0.323	0.007
NN-ISR	5.49×10^{-3}	-1.86×10^{-5}	-0.003	0.022	0.12	0.013	0.322	0.008
NN-All	5.97×10^{-3}	4.8×10^{-6}	0.001	0.018	0.18	0.017	0.261	0.010
RO	4.92×10^{-3}	5.51×10^{-5}	0.011	0.021	0.247	0.02	0.325	0.009
KOSPI200				0.027	0.120	0.012	0.412	
(c) 5 Stocks ($\rho = 0.005$), normalization								
NN-ST	5.48×10^{-3}	2.56×10^{-5}	0.005	0.025	0.157	0.014	0.349	0.023
NN-IR	5.58×10^{-3}	-3.71×10^{-5}	-0.007	0.022	0.09	0.011	0.323	0.007
NN-ISR	5.49×10^{-3}	-1.86×10^{-5}	-0.003	0.022	0.12	0.013	0.322	0.008
NN-All	5.15×10^{-3}	5.37×10^{-5}	0.01	0.02	0.253	0.021	0.3	0.016
RO	4.92×10^{-3}	5.51×10^{-5}	0.011	0.021	0.247	0.02	0.325	0.009
KOSPI200				0.027	0.120	0.012	0.412	

Table 3. Policy performances (EIT, KOSPI200)

	TE	MER	IR	CVaR	CR	Sharpe	MDD	ATC
(a) 5 Stocks ($\rho = 0$), no normalization								
NN-ST	7.22×10^{-3}	1.76×10^{-4}	0.024	0.03	0.381	0.022	0.405	n.a
NN-IR	6.54×10^{-3}	1.87×10^{-5}	0.003	0.026	0.138	0.013	0.372	n.a
NN-ISR	6.21×10^{-3}	-4.30×10^{-6}	-0.001	0.025	0.111	0.012	0.357	n.a
NN-All	5.94×10^{-3}	7.19×10^{-5}	0.012	0.023	0.26	0.02	0.309	n.a
RO	8.18×10^{-3}	3.28×10^{-5}	0.004	0.031	0.122	0.013	0.383	n.a
KOSPI200				0.027	0.120	0.012	0.412	
(b) 5 Stocks ($\rho = 0$), normalization								
NN-ST	9.93×10^{-3}	2.95×10^{-4}	0.03	0.034	0.601	0.028	0.343	n.a
NN-IR	6.54×10^{-3}	1.87×10^{-5}	0.003	0.026	0.138	0.013	0.372	n.a
NN-ISR	6.21×10^{-3}	-4.30×10^{-6}	-0.001	0.025	0.111	0.012	0.357	n.a
NN-All	7.21×10^{-3}	1.99×10^{-4}	0.028	0.027	0.471	0.027	0.32	n.a
RO	8.18×10^{-3}	3.28×10^{-5}	0.004	0.031	0.122	0.013	0.383	n.a
KOSPI200				0.027	0.120	0.012	0.412	
(c) 5 Stocks ($\rho = 0.005$), no normalization								
NN-ST	7.21×10^{-3}	1.36×10^{-4}	0.019	0.03	0.301	0.02	0.402	0.020
NN-IR	6.54×10^{-3}	6.00×10^{-7}	0	0.026	0.108	0.012	0.378	0.011
NN-ISR	6.21×10^{-3}	-3.26×10^{-5}	-0.005	0.025	0.065	0.009	0.368	0.014
NN-All	5.95×10^{-3}	5.61×10^{-5}	0.009	0.023	0.23	0.018	0.314	0.014
RO	8.18×10^{-3}	-4.15×10^{-5}	-0.005	0.031	0.005	0.007	0.401	0.037
KOSPI200				0.027	0.120	0.012	0.412	
(c) 5 Stocks ($\rho = 0.005$), normalization								
NN-ST	1.03×10^{-2}	1.88×10^{-4}	0.018	0.034	0.362	0.021	0.386	0.087
NN-IR	6.54×10^{-3}	6.00×10^{-7}	0	0.026	0.108	0.012	0.378	0.011
NN-ISR	6.21×10^{-3}	-3.26×10^{-5}	-0.005	0.025	0.065	0.009	0.368	0.014
NN-All	7.29×10^{-3}	1.33×10^{-4}	0.018	0.027	0.334	0.022	0.348	0.042
RO	8.18×10^{-3}	-4.15×10^{-5}	-0.005	0.031	0.005	0.007	0.401	0.037
KOSPI200				0.027	0.120	0.012	0.412	

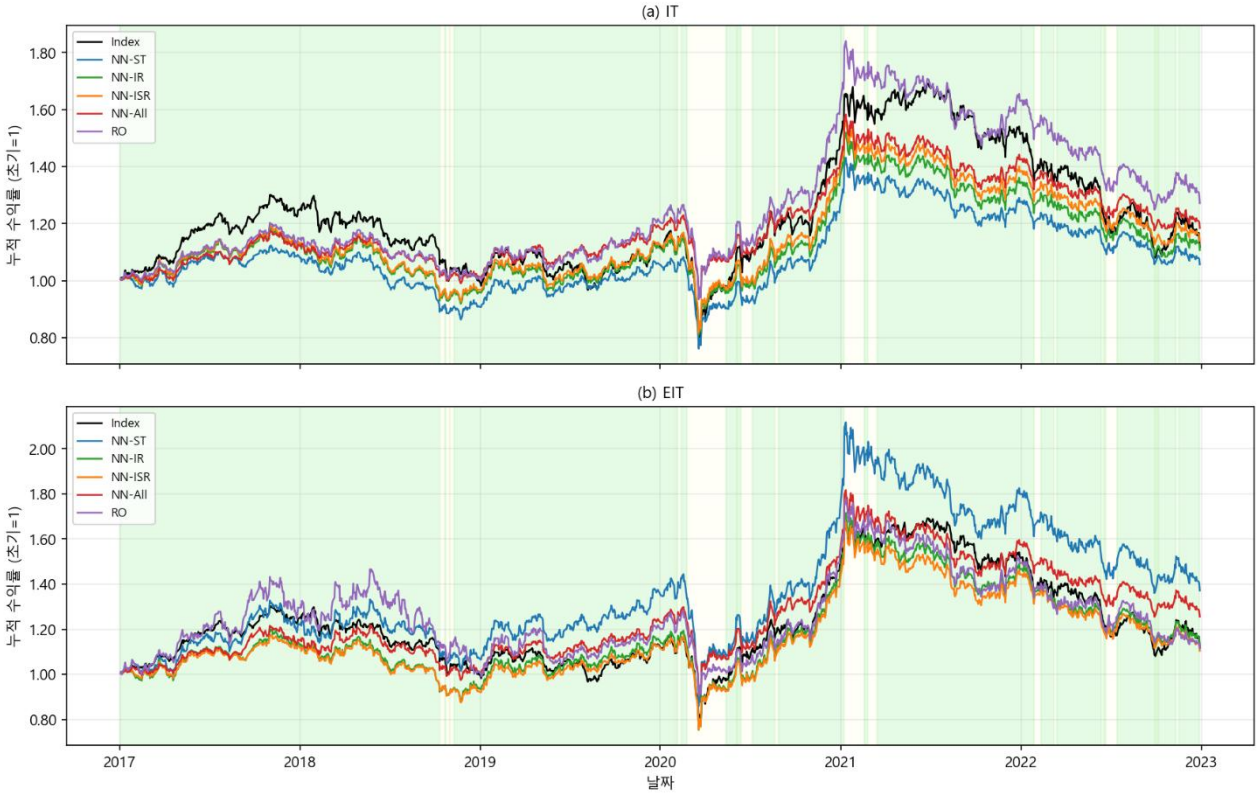

Figure 1. ρ = 0, 정규화하지 않았을 때의 누적 수익률

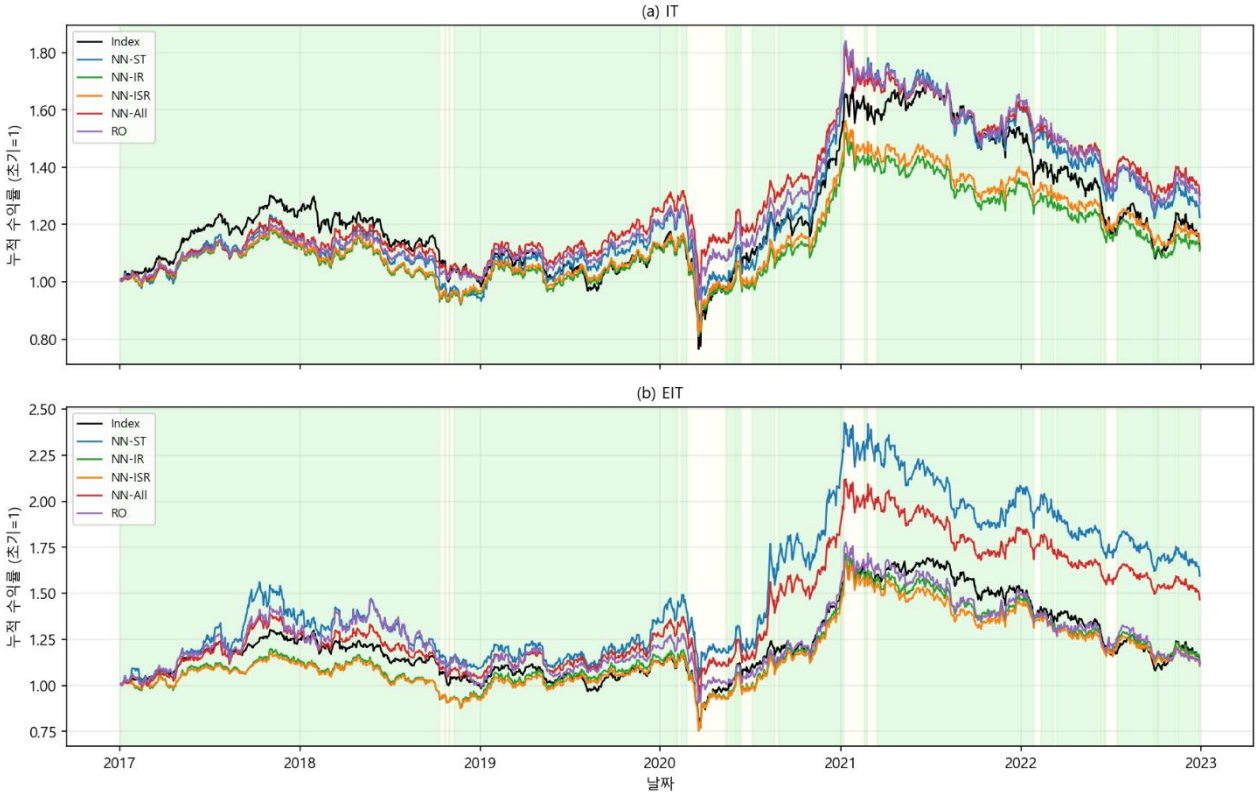

Figure 2. $\rho = 0$, 정규화했을 때의 누적 수익률

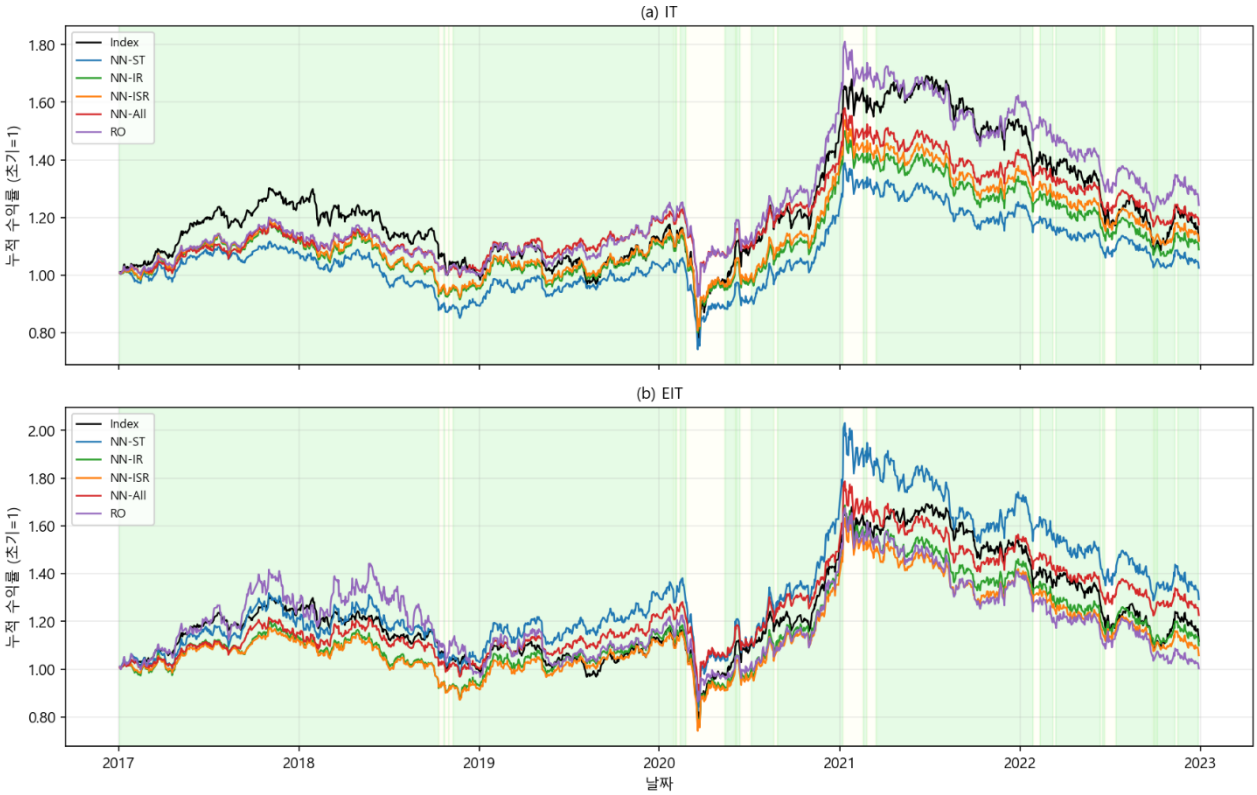

Figure 3. $\rho = 0.005$, 정규화하지 않았을 때의 누적 수익률

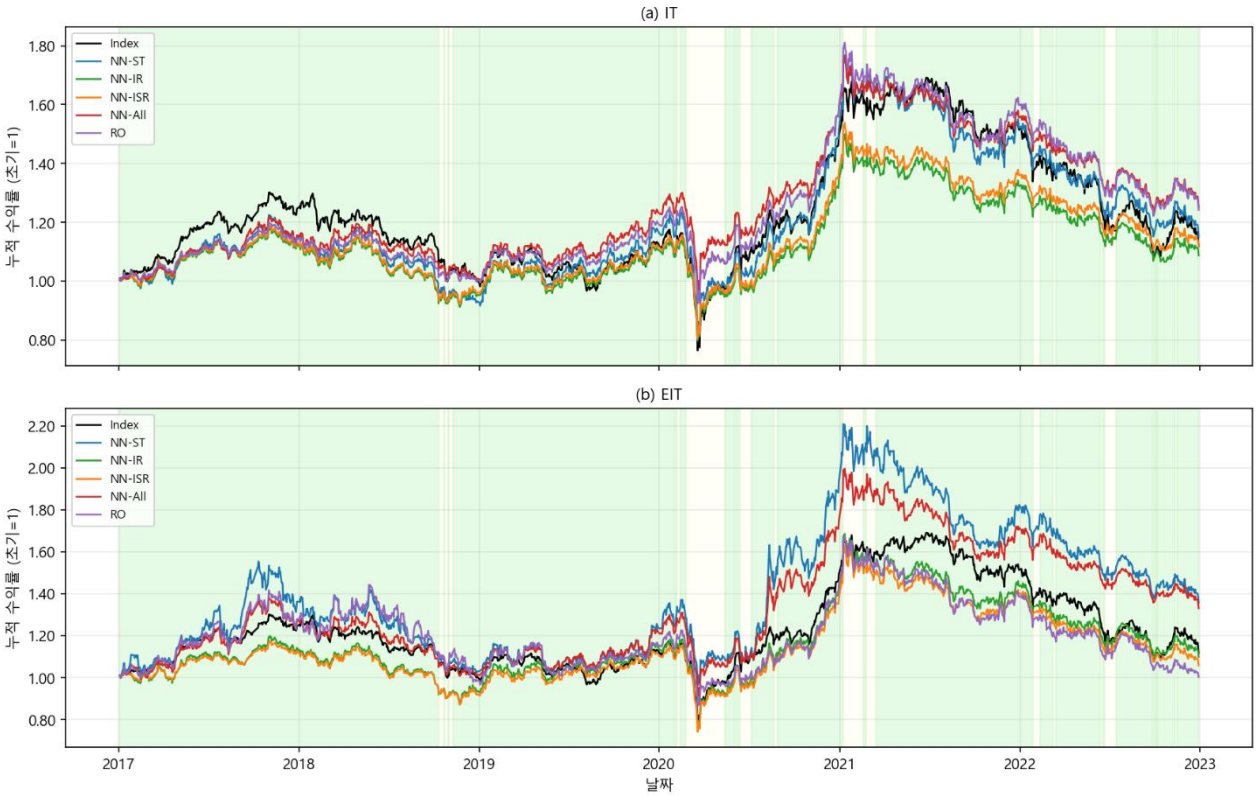

Figure 4. $\rho = 0$, 정규화했을 때의 누적 수익률

그러나 이러한 성과 개선은 동시에 TE 및 CVaR, MDD의 상승을 동반한다. Table 3에서 NN-ST의 CVaR(5%)와 MDD는 RO 대비 높은 수준을 보이며, 이는 하락 구간에서 tail risk가 확대되었음을 의미한다. 실제로 Figure에서 bear 구간(연노란색)에서는 NN-ST의 낙폭이 가장 크게 나타난다. 반면 NN-All은 MER과 CR을 개선하면서도 CVaR와 MDD 상승폭이 상대적으로 제한적이며, 수익-리스크 간 보다 균형적인 특성을 보인다.

정규화의 효과는 Table 3에서 더욱 명확하게 드러난다. normON 설정에서 NN-ST와 NN-All의 MER 및 CR은 전반적으로 증가하는 경향을 보인다. 이는 입력 특성의 정규화가 학습 안정성을 높이고 신호 민감도를 강화하여 초과수익 창출 능력을 증폭시켰음을 의미한다. 그러나 동시에 TE와 ATC(평균 거래비용) 역시 상승한다. Table 3에서 확인되듯, 정규화는 회전율 증가로 이어지며 거래비용 환경(ρ=0.005)에서 성과 감소폭을 확대한다. 특히 NN-ST는 ρ=0에서 높은 CR을 기록하지만, ρ=0.005가 도입되면 성과 감소폭이 가장 크다. 이는 정규화로 인해 포트폴리오 재조정이 더욱 빈번해졌고, 거래비용이 누적수익을 잠식했음을 보여준다.

결과적으로 Table 2는 IT 환경에서 RO의 추적 안정성을, Table 3는 EIT 환경에서 신경망 기반 전략의 초과수익 잠재력을 보여준다. 동시에 정규화는 수익 증폭 효과와 회전율 증가 효과를 동시에 유발하며, 이는 거래비용 환경에서 성과의 중요한 결정 요인으로 작용한다.

4.3.2 Portfolio Weight Dynamics

가중치 추이(Figure 5-8)는 위에서 관찰된 수익률 차이를 구조적으로 설명해준다. 특히 EIT 환경에서 전략 간 차이는 가중치 변동성에서 뚜렷하게 나타난다.

NN-ST의 경우 normOFF에서는 특정 종목 집중이 존재하나 전환이 비교적 점진적이다. 반면 normON에서는 가중치 변동이 현저히 확대되며, 특정 종목 비중이 단기간에 크게 확대·축소된다. bull 구간에서는 공격적으로 비중을 확대하고, bear 구간에서는 급격히 축소하는 패턴이 반복된다. 이러한 가중치 동학은 Table 3에서 관찰된 높은 MER 및 높은 ATC를 동시에 설명한다. 즉, 정규화는 신호의 상대적 강도를 증폭시켜 수익 기회를 적극적으로 활용하게 하지만, 동시에 회전율을 증가시켜 거래비용 부담을 키운다.

NN-All 은 보다 구조적인 가중치 재배분을 보인다. normOFF 에서는 분산된 비중 구조를 유지하지만, normON 에서는 레짐 전환 시점에서 가중치 조정 강도가 증가한다. 특히 bear 구간에서 현금 비중 확대 또는 위험 자산 축소가 보다 뚜렷하다. 이는 NN-All 이 레짐 정보와 단기 통계를 결합한 구조적 장점을 가지며, 정규화가 이를 강화했음을 보여준다.

반면 NN-IR 및 NN-ISR 는 정규화 전후 가중치 경로가 거의 동일하게 나타난다. 이는 해당 전략이 입력 스케일 변화에 덜 민감하거나 구조적으로 안정된 의사결정 규칙을 따르기 때문으로 해석된다. RO 는 특정 시점에서 극단적 집중을 보이는 전형적인 평균-분산 최적화 특성을 유지하며, 정규화의 영향을 받지 않는다.

종합하면, 가중치 추이는 정규화가 단순히 학습 안정성을 높이는 수준을 넘어 포트폴리오 재조정의 강도와 빈도를 구조적으로 변화시킨다는 점을 보여준다. 이는 누적수익률 그래프와 Table 3 에서 관찰된 수익 증폭 및 거래비용 민감도 증가 현상을 일관되게 설명한다.

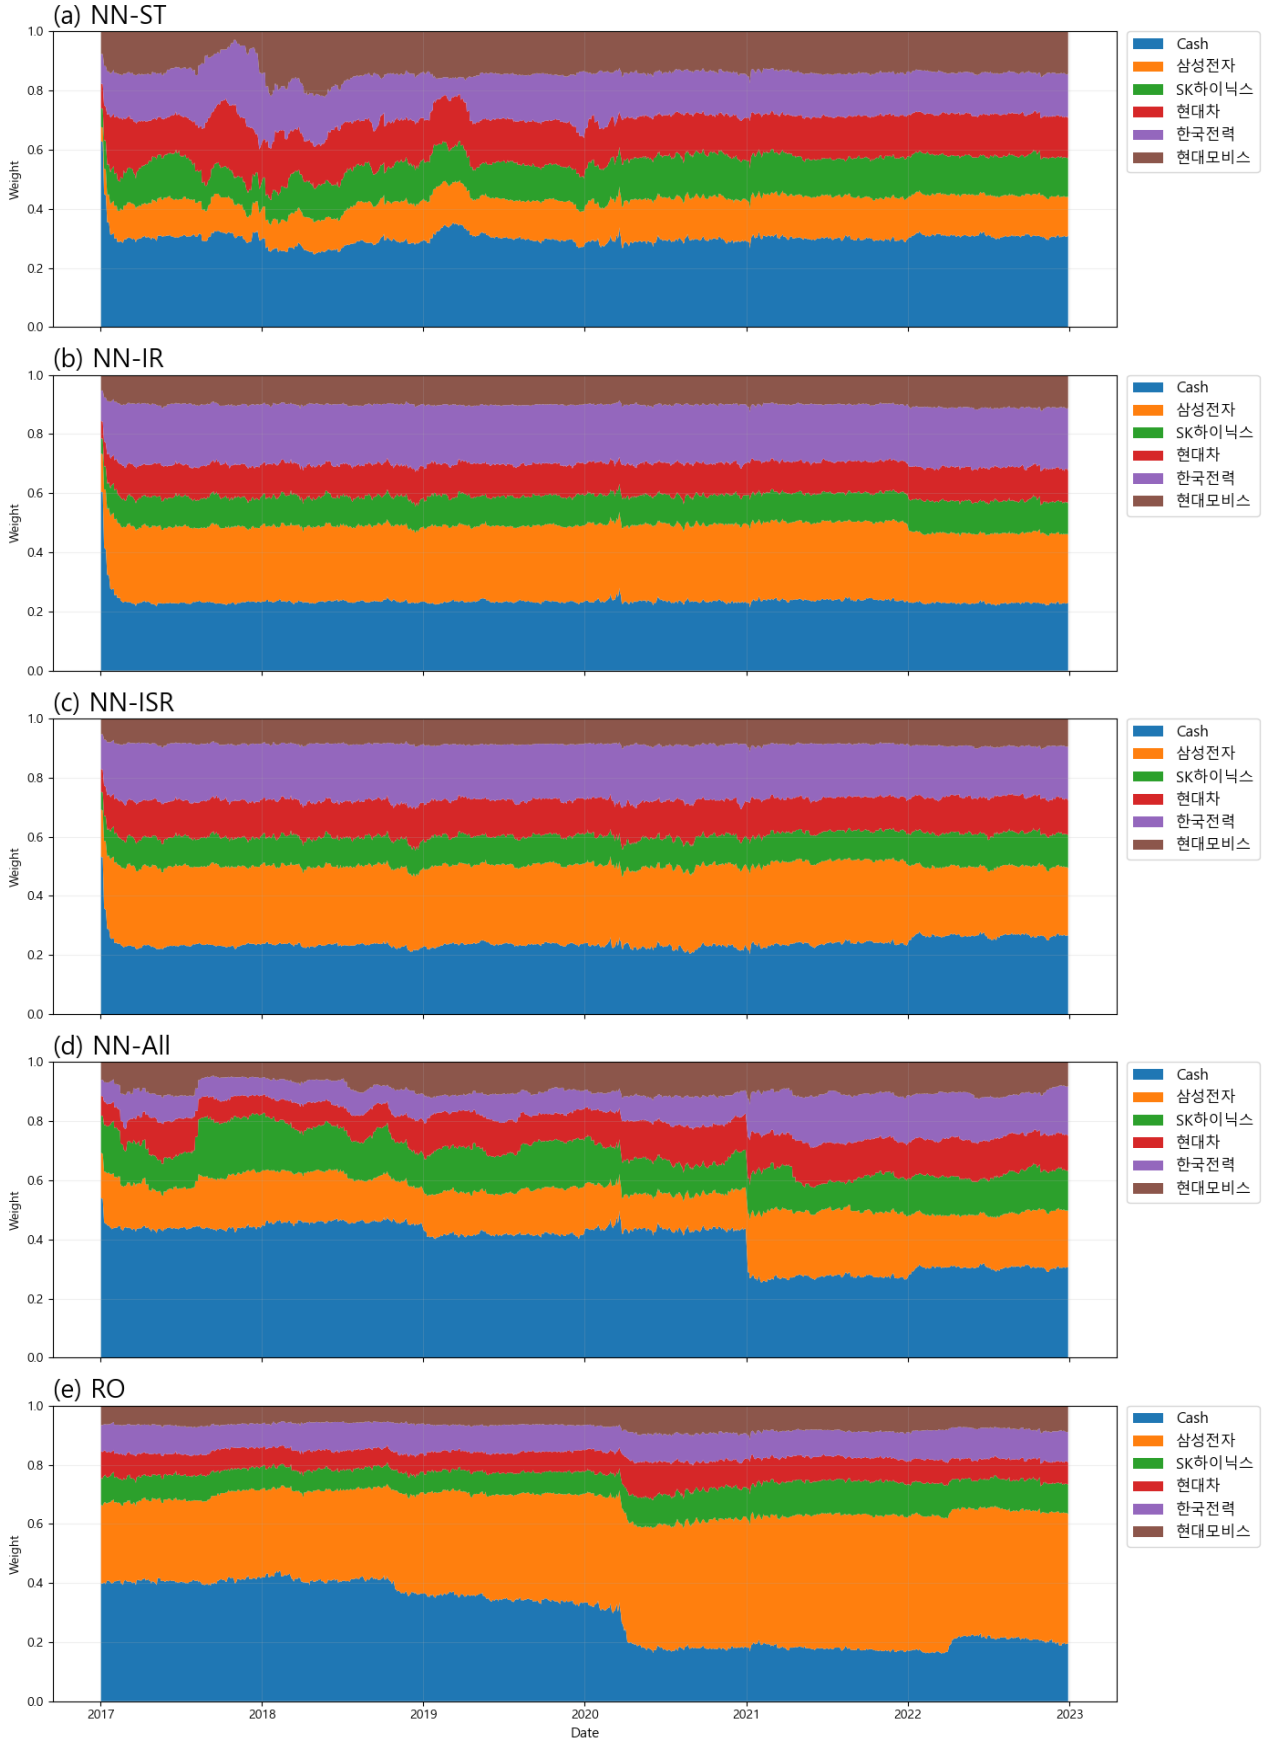

Figure 5. IT, ρ = 0.005, 정규화하지 않았을 때의 가중치 추이

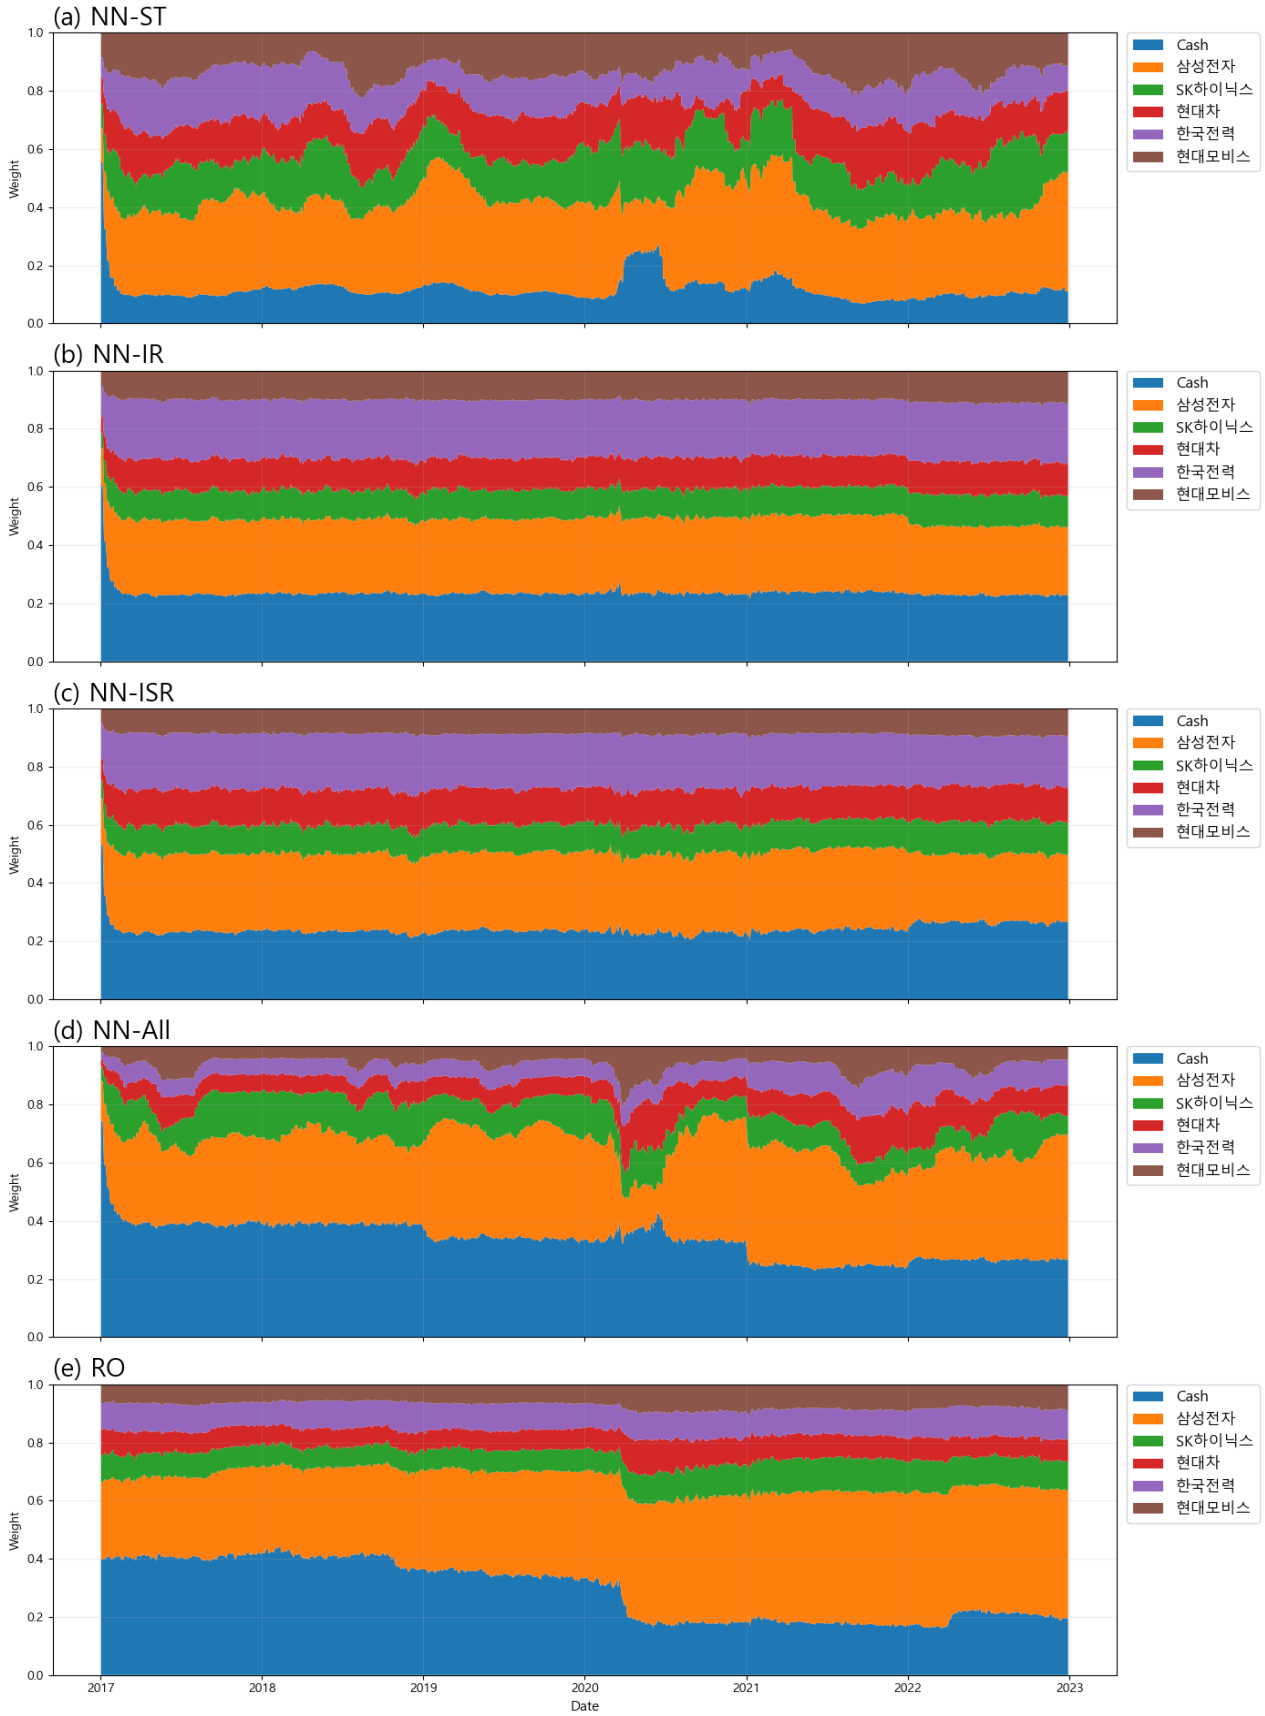

Figure 6. IT, ρ = 0.005, 정규화했을 때의 가중치 추이

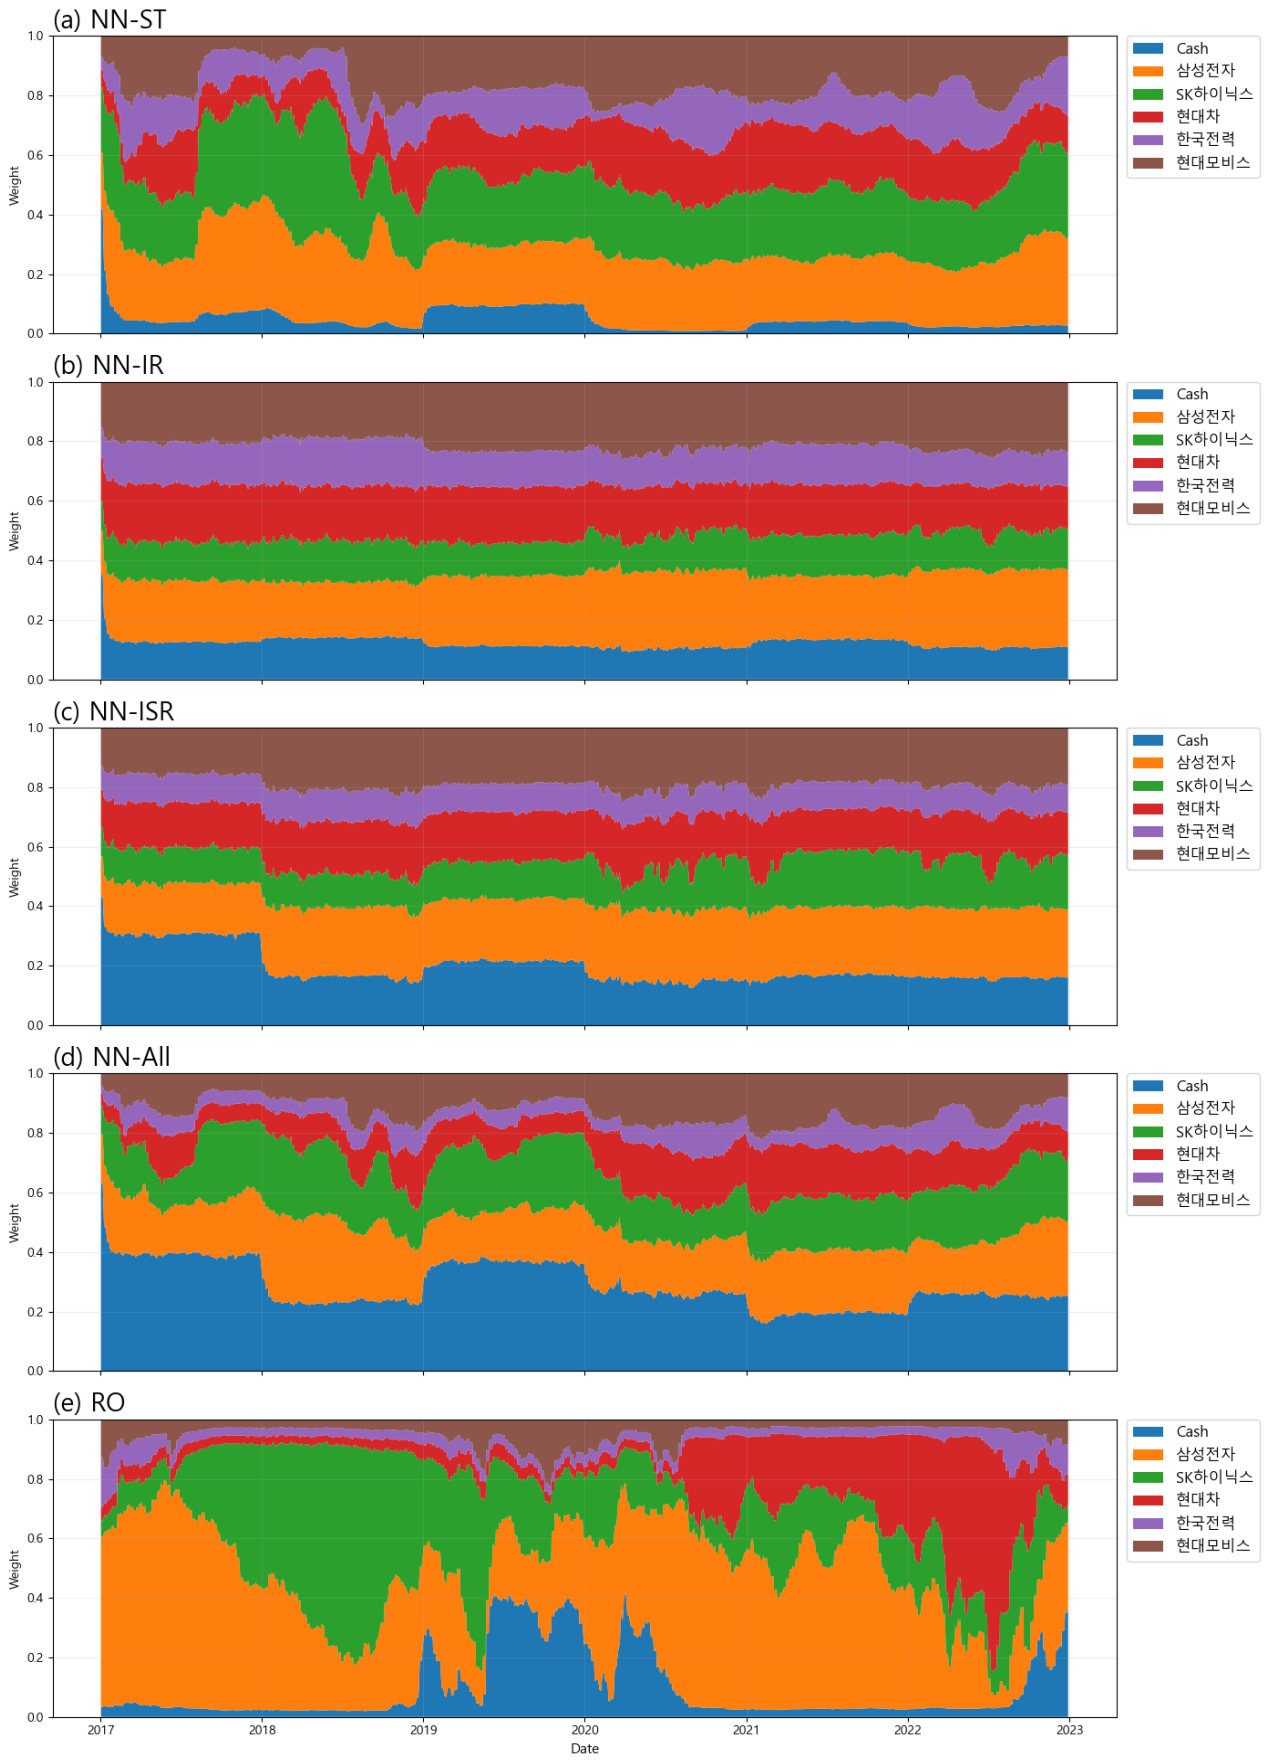

Figure 7. EIT, $\rho = 0.005$, 정규화하지 않았을 때의 가중치 추이

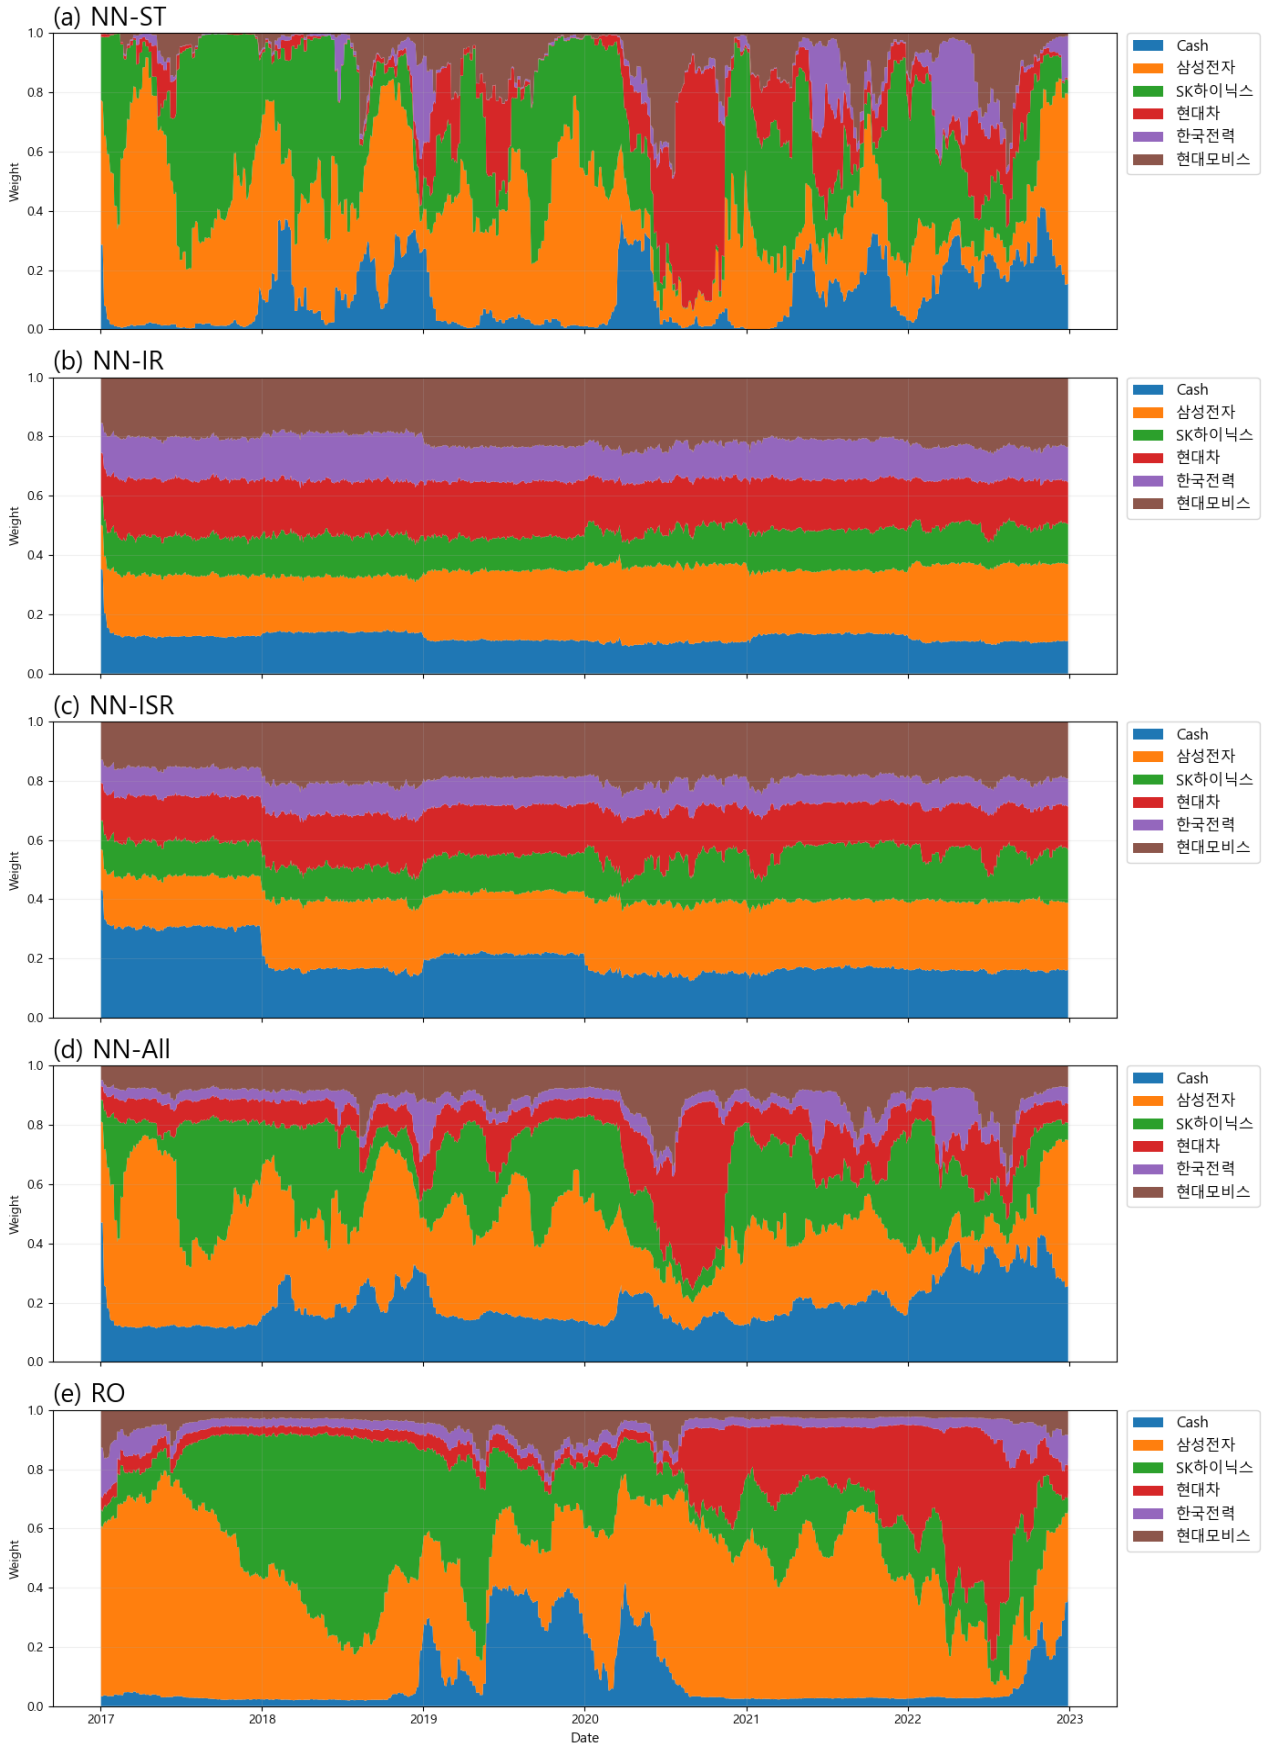

Figure 8. IT, ρ = 0.005, 정규화했을 때의 가중치 추이

5. 결론

본 연구는 딥러닝 기반 enhanced index tracking(EIT) 전략의 실증적 성과를 IT 전략 및 전통적 재최적화(RO) 방법과 비교·분석하였다. 특히 누적수익률 경로, 추적오차(TE), 초과수익(MER), Sharpe ratio, CVaR, 최대낙폭(MDD), 거래비용(ATC) 등을 종합적으로 평가함으로써, 단순 추종 전략과 초과수익 추구 전략 간의 구조적 차이를 정량적으로 확인하였다.

실증 결과는 다음과 같은 핵심 시사점을 제공한다. 첫째, 순수 추적 목적(IT) 하에서는 RO 가 여전히 가장 낮은 TE 를 달성하며 강력한 기준선으로 작동한다. 그러나 EIT 목적함수 하에서는 딥러닝 기반 전략, 특히 NN-ST 및 NN-All 이 지수 대비 유의한 초과수익을 달성하며 누적성과 측면에서 우월한 성과를 보였다. 이는 단기 통계 특성과 레짐 정보를 결합한 신경망 구조가 시장 국면에 따라 동적으로 포트폴리오를 조정함으로써 초과수익 기회를 효과적으로 포착할 수 있음을 의미한다.

둘째, 정규화는 단순한 학습 안정화 기법을 넘어 포트폴리오 동학 자체를 변화시키는 요인으로 작용하였다. 정규화를 적용한 전략은 bull 구간에서 수익을 증폭시키는 반면, bear 구간에서는 변동성과 회전율이 증가하는 경향을 보였다. 이는 거래비용 환경에서 성과에 중요한 영향을 미쳤으며, 딥러닝 기반 EIT 전략이 실무적으로 적용되기 위해서는 회전율 관리 및 비용 통제가 핵심 요소임을 시사한다.

셋째, 레짐별 누적수익률 경로와 가중치 추이를 종합적으로 분석한 결과, 딥러닝 기반 전략은 단순 추종 전략과 달리 시장 국면에 따라 적극적으로 위험 노출을 조정하는 구조적 특성을 가진다는 점이 확인되었다. 이러한 동적 자산배분 특성은 전통적 평균-분산 기반 접근과 차별화되는 핵심 경쟁력으로 볼 수 있다.

특히 국내 시장의 관점에서 볼 때, 딥러닝 기반 EIT 전략은 아직 널리 상용화되거나 대중적으로 알려진 영역은 아니다. 국내 ETF 및 인덱스 상품 대부분이 단순 추종 구조에 머물러 있는 상황에서, 추적 안정성을 유지하면서도 일정 수준의 초과수익을 추구하는 전략은 차별화된 금융상품으로 발전할 가능성이 충분하다. 본 연구의 결과는 딥러닝 기반 EIT 가 단순한 학술적 모델을 넘어 실제 자산운용 전략으로 확장될 수 있는 실증적 근거를 제시한다는 점에서 의의가 있다.

결론적으로, 딥러닝 기반 enhanced index tracking 은 수익-리스크-거래비용 간의 균형을 정교하게 설계할 수 있는 유연한 프레임워크를 제공한다. 이는 향후 국내

자산운용 산업에서 고도화된 스마트 베타 혹은 차세대 인덱스 연계 상품으로 발전할 잠재력을 갖는다. 향후 연구에서는 보다 다양한 자산군, 장기 데이터, 그리고 실제 운용 제약 조건을 반영한 추가 검증이 필요하겠으나, 본 연구는 딥러닝 기반 EIT 가 실질적으로 유의미한 전략 대안이 될 수 있음을 보여준다.

References

1. Jorion, P. (2003). Portfolio optimization with tracking-error constraints. *Financial Analysts Journal*, 59(5), 70-82.
2. Dai, X., & Li, J. (2024). Deep learning for enhanced index tracking. *SSRN Electronic Journal* (Working paper).
3. Jiang, Z., Xu, D., & Liang, J. (2017). A deep reinforcement learning framework for the financial portfolio management problem. *arXiv preprint arXiv:1706.10059*.
4. Moody, J., & Saffell, M. (2001). Learning to trade via direct reinforcement. *IEEE Transactions on Neural Networks*, 12(4), 875-889.
5. Oh, K. J., Kim, T. Y., & Min, S. (2005). Using genetic algorithm to support portfolio optimization for index tracking. *Expert Systems with Applications*, 28(2), 371-379.
6. 정재만. (2012). KOSPI200 추적 ETF 의 추적오차 분석. *한국증권학회지*, 41(2), 225-254.
7. 윤주영. (2013). KOSPI200 ETF 의 추적오차 결정요인 분석. *재무관리연구*, 30(1), 1-29.
8. 윤주영, 반주일. (2014). ETF 의 액티브 리스크와 추적오차의 결정요인. *금융공학연구*, 13(2), 45-68.